جامعة سيدي محمد بن عبد الله بفاس
ⵜⴰⵙⴷⴰⵡⵉⵜ ⵙⵉⴷⵉ ⵎⵓⵃⵎⴷ ⴱⵏ ⵄⴱⴷⵍⵍⴰⵀ ⵖ ⴼⴰⵙ
UNIVERSITÉ SIDI MOHAMED BEN ABDELLAH DE FES

كلية العلوم ظهر المهراز فاس
ⵜⴰⵖⵢⵍⵓⵜ ⵏ ⵜⵣⵔⴼⵜ ⵉⴼⵔⴷⵙⵏ ⵎⵣⵔⴰⵣ ⴼⴰⵙ
FACULTE DES SCIENCES DHAR EL MAHRAZ FES

Université Sidi Mohamed Ben Abdellah
Faculté des Sciences Dhar El Mahraz – Fès

Master Advanced Machine Learning and Multimedia Intelligence

Étude comparative des architectures CNN, VGG16, ResNet50 et ViT

pour la classification supervisée d'images de lésions cutanées

---

Réalisé par :

EL MAKHLOUFI MOHAMMED

Encadré par :

Pr. Abdelouahed Sabri

28 octobre 2026

Table des matières

1 Introduction **2**

2 Dataset et prétraitement **2**

2.1 Présentation du dataset 2

2.2 Prétraitement et division des données 3

3 Architectures **4**

3.1 CNN personnalisé 4

3.2 VGG16 4

3.3 ResNet50 4

3.4 Vision Transformer (ViT-Base/16) 4

4 Protocole expérimental **5**

4.1 Configurations 5

4.2 Métriques d'évaluation 5

5 Résultats **5**

5.1 CNN personnalisé (From Scratch) 5

5.2 VGG16 7

5.3 ResNet50 8

5.4 Vision Transformer 8

5.5 Tableau comparatif des sept configurations 9

6 Conclusion **10**

1 Introduction

La classification automatique des lésions cutanées à partir d'images dermoscopiques est un problème important en aide au diagnostic. Il est aussi difficile : les classes se ressemblent visuellement, les données médicales sont rares et leur distribution est très déséquilibrée.

L'objectif de ce travail pratique est de réaliser une **étude expérimentale comparative** de quatre architectures de Deep Learning appliquées à la classification multiclasse (7 classes) d'images de lésions cutanées :

— un réseau convolutionnel (CNN) personnalisé ;
— VGG16 ;
— ResNet50 ;
— Vision Transformer ViT-Base/16.

Deux stratégies d'apprentissage sont comparées :

— **From Scratch** : entraînement à partir de poids initialisés aléatoirement ;
— **Fine-Tuning** : adaptation d'un modèle préentraîné sur ImageNet, avec mise à jour de tous les paramètres.

Au total, **sept configurations** sont étudiées (le CNN personnalisé n'existe qu'en From Scratch). Elles sont comparées par leurs métriques de classification, leurs courbes d'apprentissage, leurs matrices de confusion et leur temps d'entraînement.

2 Dataset et prétraitement

2.1 Présentation du dataset

Le dataset HAM500 est un sous-ensemble de HAM10000. Il contient **500 images** de lésions cutanées réparties en **7 classes**. Il comprend un dossier d'images (`HAM500_images`) et un fichier de métadonnées (`HAM500_metadata.csv`) avec les colonnes `lesion_id`, `image_id` et `label`.

Table 1 – Distribution des classes dans HAM500.

Classe	Images	Part (%)
nv (naevus mélanocytaire)	332	66,4
bkl (kératose bénigne)	57	11,4
mel (mélanome)	43	8,6
bcc (carcinome basocellulaire)	34	6,8
akiec (kératose actinique)	21	4,2
vasc (lésion vasculaire)	8	1,6
df (dermatofibrome)	5	1,0
Total	**500**	**100**

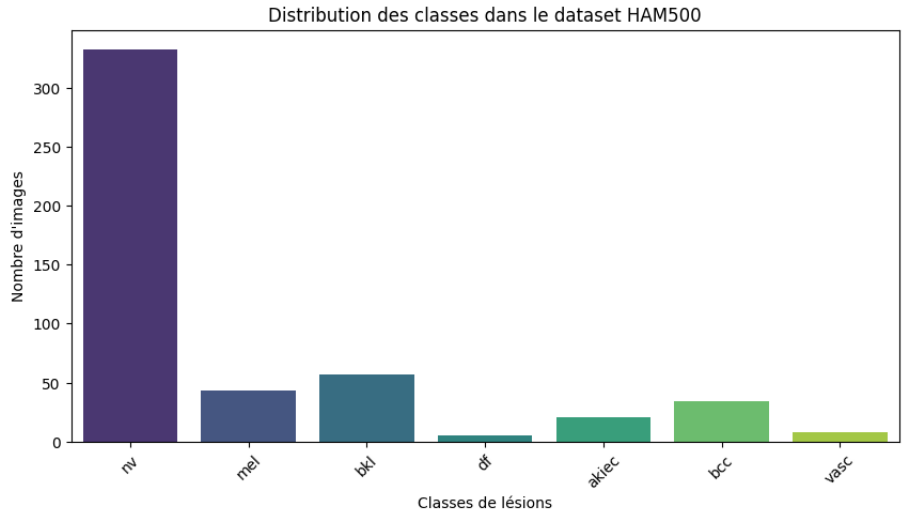


FIGURE 1 – Distribution des classes du dataset HAM500.

Interprétation. Le dataset est **fortement déséquilibré** : la classe `nv` représente à elle seule 66,4 % des images, tandis que `vasc` et `df` n'en comptent respectivement que 8 et 5. Ce déséquilibre a une conséquence directe : un classifieur qui prédit toujours `nv` obtient environ 66 % d'accuracy sans rien apprendre. L'accuracy seule est donc trompeuse, et les métriques macro (Precision, Recall, F1) seront essentielles pour juger les modèles.

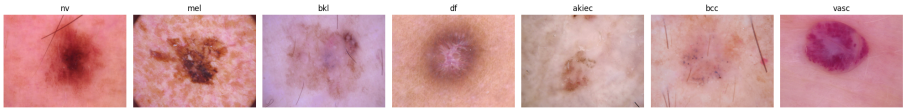


FIGURE 2 – Un exemple d'image par classe.

Interprétation. Les images montrent une forte variabilité de couleur, de forme et de contours à l'intérieur d'une même classe, et des ressemblances entre classes différentes (par exemple entre naevus et mélanome). La tâche est donc intrinsèquement difficile, même pour un modèle correctement entraîné.

2.2 Prétraitement et division des données

1. **Redimensionnement** de toutes les images à 224×224 pixels, format attendu par VGG16, ResNet50 et ViT-B/16.
2. **Encodage des étiquettes** : `LabelEncoder` (correspondance : akiec = 0, bcc = 1, bkl = 2, df = 3, mel = 4, nv = 5, vasc = 6), puis encodage one-hot pour la Categorical Crossentropy.
3. **Division stratifiée** avec `random_state=42` : 20 % pour le test, puis 20 % du reste pour la validation, soit 64 % / 16 % / 20 %.

TABLE 2 – Taille des ensembles de données.

Ensemble	Images	Part
Entraînement	320	64 %
Validation	80	16 %
Test	100	20 %

La stratification conserve la proportion de chaque classe dans les trois ensembles. L'ensemble de test contient ainsi 66 images `nv`, 11 `bkl`, 9 `mel`, 7 `bcc`, 4 `akiec`, 2 `vasc` et 1 `df`. Les mêmes ensembles sont utilisés pour toutes les expériences, et le jeu de test n'intervient pas dans le choix des hyperparamètres (l'arrêt anticipé et la sélection des meilleurs poids reposent uniquement sur la perte de validation).

3 Architectures

3.1 CNN personnalisé

Le CNN est entraîné From Scratch. Il enchaîne quatre blocs convolutionnels (convolutions 3×3, ReLU, `padding="same"`, MaxPooling 2×2), avec 32, 64, 128 puis 256 filtres. Ils sont suivis d'un `GlobalAveragePooling2D` et d'une tête de classification (Dense 128 ReLU, Dropout 0,5, Dense 7 Softmax). Il compte **615 975 paramètres**, tous entraînables.

3.2 VGG16

VGG16 est un réseau convolutionnel profond et homogène : empilement de convolutions 3×3 et de max-poolings. Sa base convolutive (sans les couches denses d'origine) compte environ 14,7 millions de paramètres. Sa profondeur sans connexions résiduelles rend l'optimisation sensible à l'initialisation.

3.3 ResNet50

ResNet50 introduit les **connexions résiduelles** (*skip connections*) qui facilitent la propagation du gradient dans un réseau profond. Il utilise aussi des couches de Batch Normalization. Sa base compte environ 23,6 millions de paramètres.

3.4 Vision Transformer (ViT-Base/16)

Le ViT découpe l'image en 196 patchs de 16×16 pixels, les projette en embeddings de dimension 768, puis les traite par 12 blocs Transformer à 12 têtes d'attention. Le jeton `[CLS]` de sortie sert à la classification. Il compte environ 86 millions de paramètres.

Contrairement aux CNN, il ne possède pas de biais inductif de localité ni d'invariance par translation : il doit les apprendre à partir des données.

4 Protocole expérimental

4.1 Configurations

— **From Scratch** : poids aléatoires, toutes les couches entraînées.
— **Fine-Tuning** : poids ImageNet, tête remplacée, **toutes** les couches dégelées, avec un learning rate très faible pour ne pas détruire les connaissances préapprises.

TABLE 3 – Hyperparamètres communs et spécifiques.

Paramètre	**Valeur**
Optimiseur	Adam
Fonction de perte	Categorical Crossentropy
Batch size	16
Époques maximales	30
Early stopping	patience 5 sur `val_loss`, restauration des meilleurs poids
Learning rate – CNN personnalisé	10^{-3}
Learning rate – autres From Scratch	10^{-4}
Learning rate – Fine-Tuning	10^{-5}
Graine aléatoire (division des données)	42

Les modèles sont implémentés avec TensorFlow/Keras (le ViT avec `keras-hub`, preset `vit_base_patch16_224_imagenet` pour le Fine-Tuning) et entraînés sur Google Colab.

4.2 Métriques d'évaluation

Sur l'ensemble de test : Accuracy, Precision, Recall et F1-score (macro et par classe), matrice de confusion, nombre de paramètres et temps d'entraînement. Le **F1 macro** est la métrique de référence : il donne le même poids à chaque classe et révèle donc l'échec sur les classes rares, que l'accuracy masque.

5 Résultats

5.1 CNN personnalisé (From Scratch)

L'entraînement s'arrête à l'époque 16 (meilleurs poids : époque 11) en **48,9 s**. L'accuracy d'entraînement et de validation reste figée autour de 66 %, et la loss de validation oscille sans tendance claire. Sur le test : accuracy = 0,66 et loss = 1,02.

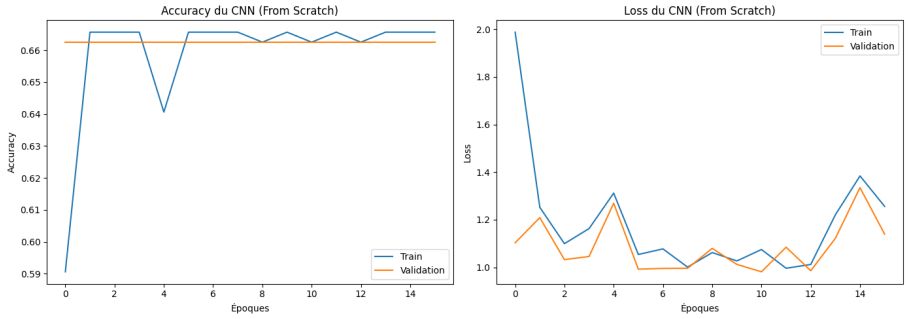


FIGURE 3 – Courbes d'accuracy et de loss du CNN personnalisé.

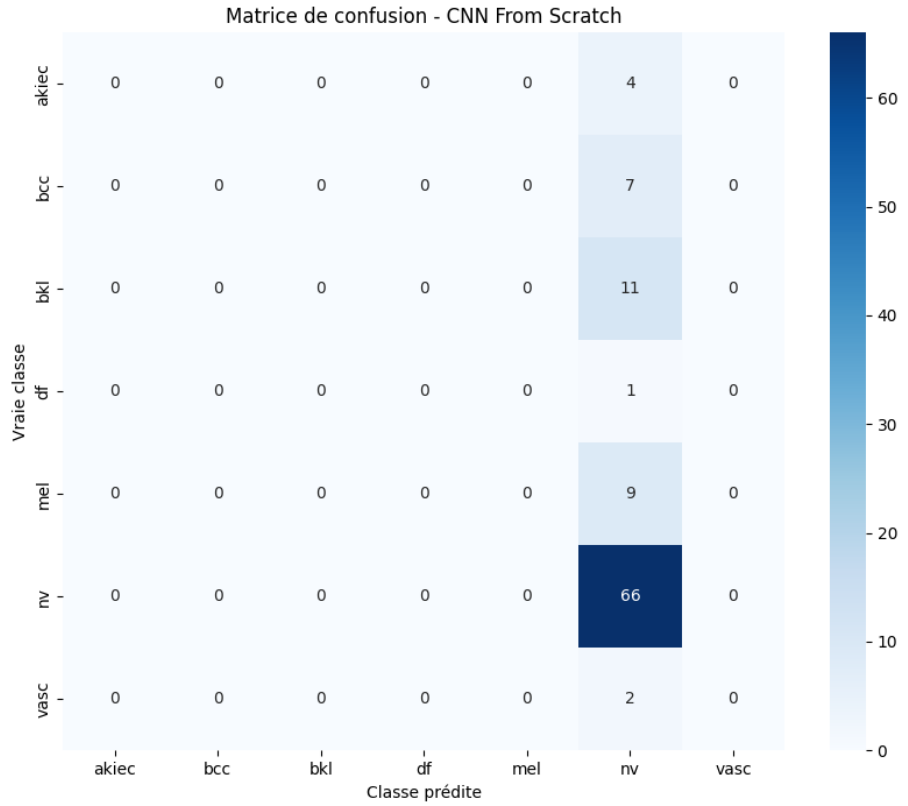


FIGURE 4 – Matrice de confusion du CNN personnalisé.

Interprétation. Le rapport de classification montre un rappel de 1,00 pour `nv` et de 0,00 pour les six autres classes. Le modèle prédit `nv` pour toutes les images : il a convergé vers le **classifieur majoritaire**. L'accuracy de 66 % reflète uniquement la proportion de `nv` dans le test ; le F1 macro de 0,11 révèle l'absence d'apprentissage réel.

5.2 VGG16

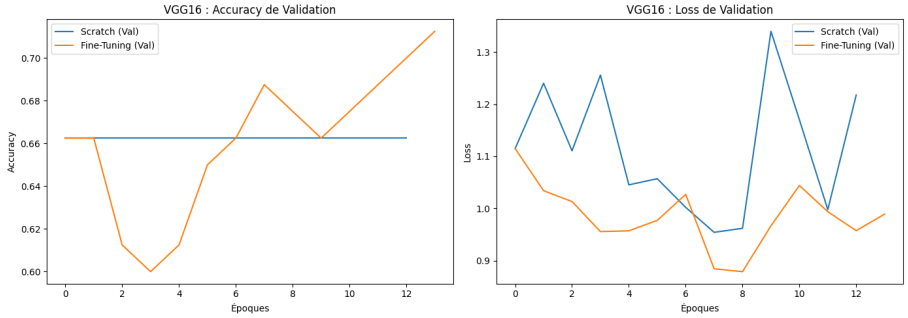


FIGURE 5 – VGG16 : From Scratch vs Fine-Tuning (validation).

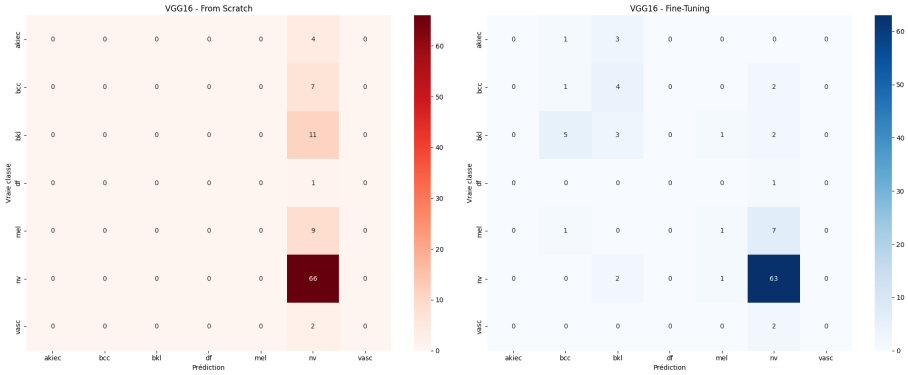


FIGURE 6 – Matrices de confusion de VGG16 (From Scratch à gauche, Fine-Tuning à droite).

From Scratch. L'entraînement s'arrête à l'époque 13 (meilleurs poids : époque 8). Comme pour le CNN, l'accuracy de validation reste à 66,25 % : le modèle prédit toujours `nv`.

Fine-Tuning. L'entraînement s'arrête à l'époque 14 (meilleurs poids : époque 9). L'accuracy d'entraînement monte progressivement (de 44 % à environ 83 %) et l'accuracy de validation atteint 70–71 %. Sur le test : accuracy = 0,68, F1 macro = 0,21. Le modèle reconnaît `bcc`, `bkl` et `mel` de manière partielle (F1 de 0,13, 0,26 et 0,17).

Interprétation. Le préentraînement permet à VGG16 de sortir du classifieur majoritaire : les gains sont faibles en accuracy (+2 points) mais nets en F1 macro (0,11 → 0,21). La différence d'accuracy est ici trop petite pour être significative sur 100 images de test.

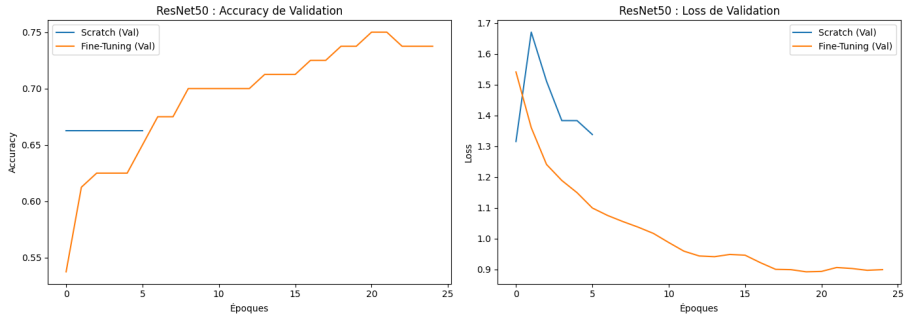


FIGURE 7 – ResNet50 : From Scratch vs Fine-Tuning (validation).

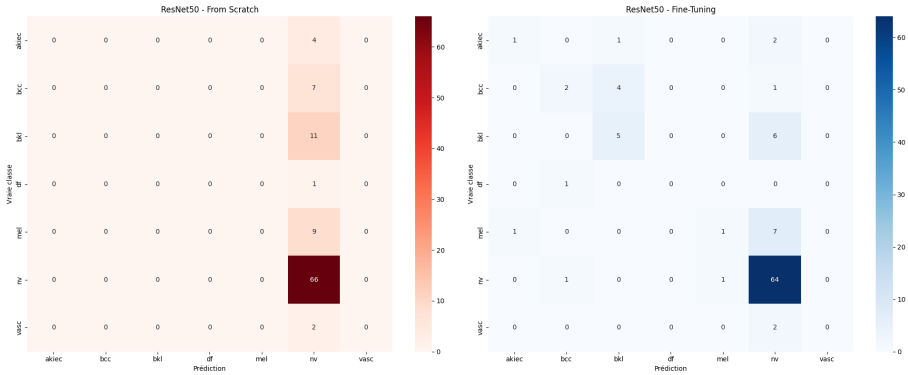


FIGURE 8 – Matrices de confusion de ResNet50 (From Scratch à gauche, Fine-Tuning à droite).

5.3 ResNet50

From Scratch. L'entraînement s'arrête dès l'époque 6, les meilleurs poids étant ceux de l'époque 1. La loss de validation ne s'améliore jamais, et le modèle prédit toujours `nv` (F1 macro = 0,11).

Fine-Tuning. L'entraînement s'arrête à l'époque 25 (meilleurs poids : époque 20). L'accuracy d'entraînement atteint environ 98–99 % alors que celle de validation plafonne à 73–75 %. Sur le test : accuracy = 0,73, precision macro = 0,40, recall macro = 0,30, F1 macro = 0,32. Le modèle reconnaît des exemples de `akiec`, `bcc`, `bkl` et `mel` (F1 de 0,33, 0,36, 0,48 et 0,18).

5.4 Vision Transformer

From Scratch. L'entraînement s'arrête à l'époque 8 (meilleurs poids : époque 3). L'accuracy de validation reste à 66,25 % : le modèle prédit toujours `nv` (F1 macro = 0,11).

Fine-Tuning. L'entraînement s'arrête à l'époque 21 (meilleurs poids : époque 16). L'accuracy d'entraînement reste proche de 70–74 %, celle de validation de 66–69 %. Sur le test : accuracy = 0,65, precision macro = 0,35, recall macro = 0,21, F1 macro = 0,21. Le ViT obtient la meilleure précision sur `mel` (1,00), mais avec un rappel de 0,11 : une seule des neuf images de mélanome est retrouvée.

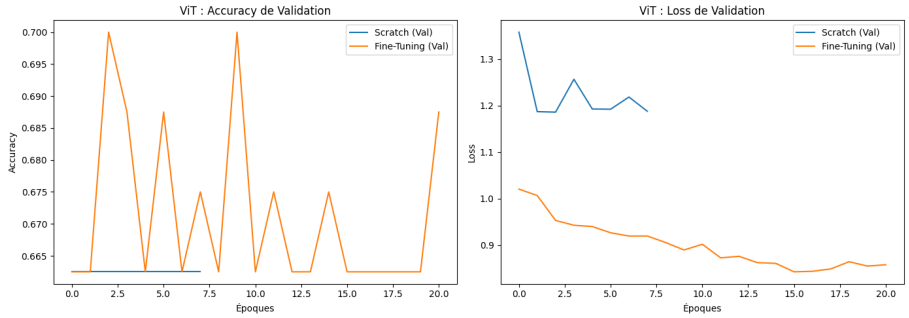


FIGURE 9 – ViT : From Scratch vs Fine-Tuning (validation).

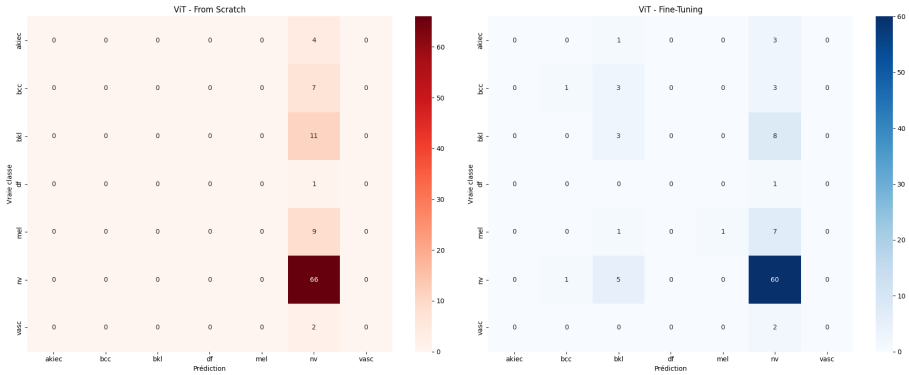


FIGURE 10 – Matrices de confusion du ViT (From Scratch à gauche, Fine-Tuning à droite).

Interprétation. L'accuracy du ViT Fine-Tuning (0,65) est légèrement *inférieure* à celle du modèle majoritaire (0,66), alors que son F1 macro est meilleur (0,21 contre 0,11). Ce cas illustre bien pourquoi l'accuracy seule est insuffisante sur un dataset déséquilibré.

5.5 Tableau comparatif des sept configurations

TABLE 4 – Performances sur l'ensemble de test (100 images).

Modèle	**Accuracy**	**Precision macro**	**Recall macro**	**F1 macro**	**Temps (s)**
CNN personnalisé – Scratch	0,66	0,09	0,14	0,11	49
VGG16 – Scratch	0,66	0,09	0,14	0,11	≈100
VGG16 – Fine-Tuning	0,68	0,22	0,21	0,21	≈90
ResNet50 – Scratch	0,66	0,09	0,14	0,11	≈100
ResNet50 – Fine-Tuning	**0,73**	**0,40**	**0,30**	**0,32**	≈165
ViT – Scratch	0,66	0,09	0,14	0,11	≈170
ViT – Fine-Tuning	0,65	0,35	0,21	0,21	≈355

TABLE 5 – F1-score par classe sur le test (support entre parenthèses).

Modèle	**akiec** (4)	**bcc** (7)	**bkl** (11)	**df** (1)	**mel** (9)	**nv** (66)	**vasc** (2)
4 modèles Scratch	0,00	0,00	0,00	0,00	0,00	0,80	0,00
VGG16 – FT	0,00	0,13	0,26	0,00	0,17	0,88	0,00
ResNet50 – FT	0,33	0,36	0,48	0,00	0,18	0,86	0,00
ViT – FT	0,00	0,22	0,25	0,00	0,20	0,80	0,00

Interprétation. Les quatre modèles From Scratch donnent exactement les mêmes métriques (accuracy 0,66, F1 macro 0,11) : aucun n'apprend autre chose que la classe majoritaire. Seuls les modèles Fine-Tuning se démarquent, et ResNet50 est le meilleur sur toutes les métriques macro.

6 Conclusion

Cette étude a comparé sept configurations (CNN personnalisé, VGG16, ResNet50 et ViT, en From Scratch et en Fine-Tuning) pour la classification de 7 classes de lésions cutanées sur HAM500. Les principaux résultats sont les suivants :

— Les quatre modèles entraînés From Scratch échouent de la même manière : ils prédisent toujours la classe majoritaire `nv` (accuracy 0,66, F1 macro 0,11).

— Le Fine-Tuning améliore le F1 macro pour les trois architectures préentraînées. ResNet50 Fine-Tuning est le meilleur modèle (accuracy 0,73, F1 macro 0,32).

— Le ViT, plus lourd et plus lent, n'apporte pas d'avantage sur ce petit dataset.

— Le nombre de paramètres n'explique pas les performances ; le déséquilibre de classes est le facteur dominant.

Les classes rares (`df`, `vasc`) et le mélanome restent très mal reconnus.